# FINE-TUNING MULTIDOMÍNIO COM QLoRA PARA RACIOCÍNIO FINANCEIRO E ANÁLISE DE FALHAS INDUSTRIAIS

# MULTIDOMAIN FINE-TUNING WITH QLoRA FOR FINANCIAL REASONING AND INDUSTRIAL FAILURE ANALYSIS

**Nicoli Felipe**[1], [i]

**Vinicius de Jesus Silva**[2], [ii]

**Jéssica Franzon Cruz do Espírito Santo**[3], [iii]

## RESUMO

Este estudo avalia a especialização e o equilíbrio multidomínio do modelo Qwen2.5-7B-Instruct em raciocínio financeiro e análise de falhas industriais, utilizando a técnica Quantized Low-Rank Adaptation (QLoRA). Foram comparados o modelo base, dois modelos submetidos a fine-tuning (FT) especializado e um modelo híbrido em duas configurações experimentais. No FinQA, o melhor resultado foi obtido pelo FT-FinQA com contexto de 4.096 tokens (15,42%). No FailureSensorIQ, avaliado como tarefa multirrótulo, o FT-Failure com 1.024 tokens alcançou 96,63% de correspondência exata e F1 macro de 0,989. O FT-Híbrido com 1.024 tokens apresentou o melhor equilíbrio entre os domínios na primeira bateria, medido pela média harmônica (H = 18,75%), resultado não reproduzido na segunda. Os resultados indicam ganhos de desempenho associados aos ajustes especializados nos protocolos avaliados, embora as diferenças entre as baterias não possam ser atribuídas exclusivamente à janela de contexto, pois outros hiperparâmetros também variaram.

**Palavras-chave:** modelos de linguagem; QLoRA; FinQA; análise de falhas industriais; aprendizado multidomínio.

## ABSTRACT

This study evaluates the specialization and multidomain balance of the Qwen2.5-7B-Instruct model in financial reasoning and industrial failure analysis using Quantized Low-Rank Adaptation (QLoRA). The base model, two specialized fine-tuned (FT) models, and a hybrid model were compared under two experimental settings. On FinQA, the best result was achieved by FT-FinQA with a 4,096-token context window (15.42%). On FailureSensorIQ, evaluated as a multilabel task, FT-Failure with 1,024 tokens achieved 96.63% exact-match accuracy and a macro F1-score of 0.989. The 1,024-token FT-Hybrid showed the best balance across domains in the first battery, measured by the harmonic mean (H = 18.75%), but this result was not reproduced in the second. The results indicate performance gains associated with specialized fine-tuning under the evaluated protocols, although differences between batteries cannot be attributed solely to context length because other hyperparameters also varied.

**Keywords:** large language models; QLoRA; FinQA; industrial failure analysis;

[1] Graduanda em Ciência de Dados pelo Centro Universitário Senai São Paulo Campus São Caetano do Sul -Centro
E-mail: nicolifelipe01@gmail.com

[2] Graduado em Ciência de Dados pelo Centro Universitário Senai São Paulo Campus São Caetano do Sul -Centro
E-mail: viniciusdejesussilva12@gmail.com

[3] Docente em Ciência de Dados pelo Centro Universitário Senai São Paulo Campus São Caetano do Sul -Centro
E-mail: jessica.santo@sp.senai.br

multidomain learning.

## 1 INTRODUÇÃO

Falhas de equipamentos, paradas de produção e problemas de qualidade podem comprometer a produtividade e produzir consequências econômicas para as organizações. A análise desses fenômenos envolve capacidades distintas, como interpretar informações numéricas e reconhecer relações entre condições operacionais, sensores e modos de falha (ALSYOUF, 2007; JARDINE; LIN; BANJEVIC, 2006).

O Financial Question Answering (FinQA) é um conjunto de dados empregado como benchmark para treinar e avaliar modelos em raciocínio numérico sobre relatórios financeiros, combinando informações textuais e tabulares em questões que podem exigir uma ou mais etapas de cálculo (CHEN et al., 2021). O FailureSensorIQ é um conjunto de dados e benchmark de perguntas de múltipla escolha desenvolvido para avaliar a capacidade dos modelos de compreender relações entre sensores, ativos e modos de falha industriais (CONSTANTINIDES et al., 2025). Neste estudo, ambos foram utilizados tanto no fine-tuning quanto na avaliação das configurações especializadas e híbrida. Embora relacionados no contexto organizacional, esses benchmarks avaliam tarefas independentes; assim, permitem comparar o desempenho de um mesmo modelo nos dois domínios, mas não demonstram sua capacidade de relacionar diretamente uma falha industrial às suas consequências financeiras (CHEN et al., 2021; CONSTANTINIDES et al., 2025).

Diante disso, este estudo compara o Qwen2.5-7B-Instruct, modelo de linguagem com 7 bilhões de parâmetros ajustado para seguir instruções, antes e após o fine-tuning com dados financeiros, industriais ou de ambos os domínios. O modelo foi escolhido por combinar capacidades relatadas de seguimento de instruções, processamento de dados estruturados e raciocínio matemático (YANG et al., 2024). O objetivo é examinar a especialização e o equilíbrio multidomínio em dois protocolos de contexto.

## 2 REVISÃO DE LITERATURA

Em ambientes industriais, falhas de equipamentos, paradas e problemas de qualidade afetam a disponibilidade dos ativos e a continuidade da produção, podendo gerar perdas econômicas. Por essa razão, a manutenção não se limita à recuperação técnica dos equipamentos, mas integra decisões relacionadas à produtividade e à rentabilidade organizacional (ALSYOUF, 2007). Abordagens baseadas na condição dos ativos utilizam informações provenientes de sensores para identificar alterações operacionais e apoiar o diagnóstico e o prognóstico de falhas (JARDINE; LIN; BANJEVIC, 2006). Nesse contexto, conhecimentos industriais e financeiros são complementares para a tomada de decisão, embora exijam formas distintas de processamento da informação.

Essas capacidades são representadas, neste estudo, por dois benchmarks independentes. O FinQA exige que o modelo localize informações em textos e tabelas financeiras e execute operações matemáticas para responder a perguntas numéricas (CHEN et al., 2021). O FailureSensorIQ, por sua vez, avalia o reconhecimento de relações entre sensores, ativos e modos de falha, incluindo questões com múltiplas alternativas corretas (CONSTANTINIDES et al., 2025). Assim, os conjuntos permitem avaliar capacidades especializadas em cada domínio e verificar se um mesmo modelo

consegue preservá-las após diferentes estratégias de ajuste.

A adaptação de baixa ordem (*Low-Rank Adaptation* — LoRA) permite ajustar modelos por meio de matrizes adicionais treináveis, mantendo congelados os parâmetros originais (HU et al., 2022). Sua combinação com quantização, denominada *Quantized Low-Rank Adaptation* (QLoRA), reduz a memória necessária durante o ajuste (DETTMERS et al., 2023). Essas técnicas possibilitam comparar, a partir da mesma arquitetura, ajustes realizados separadamente com dados financeiros e industriais e um ajuste híbrido com exemplos de ambos. Essa comparação permite examinar se o treinamento conjunto mantém um desempenho equilibrado ou favorece um domínio em detrimento do outro.

## 3 METODOLOGIA

Foram utilizados os conjuntos FinQA, composto por questões de raciocínio numérico baseadas em textos e tabelas financeiras (CHEN et al., 2021), e FailureSensorIQ, formado por questões sobre sensores, ativos e modos de falha industriais, incluindo itens com múltiplas alternativas corretas (CONSTANTINIDES et al., 2025). Após a padronização dos registros e a remoção de exemplos vazios ou duplicados, permaneceram 6.156 exemplos do FinQA e 8.296 do FailureSensorIQ.

Com semente 42, cada conjunto foi embaralhado e dividido aleatoriamente em 80% para treinamento, 10% para validação e 10% para teste. As divisões resultaram em 4.924/615/617 exemplos no FinQA e 6.636/829/831 no FailureSensorIQ. Os metadados foram preservados apenas para rastreabilidade e não integraram as entradas do modelo. Não foram encontrados prompts textualmente idênticos entre treinamento e teste; contudo, essa verificação não exclui semelhanças semânticas ou exemplos provenientes de um mesmo documento, ativo ou estrutura de questão.

A arquitetura Qwen2.5-7B-Instruct foi avaliada em quatro configurações, sendo FT a abreviação adotada para fine-tuning: Base, sem ajuste; FT-FinQA, ajustado com dados financeiros; FT-Failure, ajustado com dados industriais; e FT-Híbrido, ajustado com dados de ambos os conjuntos. No FT-Híbrido, os conjuntos de treinamento foram concatenados sem reamostragem, preservando-se suas quantidades originais de exemplos. Os limites de contexto foram utilizados para representar dois perfis operacionais. O FinQA combina textos e tabelas de relatórios financeiros e inclui questões com operações numéricas em uma ou mais etapas, o que pode demandar contextos mais extensos (CHEN et al., 2021). Nesse cenário, o limite de 1.024 tokens preserva integralmente os exemplos do FailureSensorIQ e permite avaliar o modelo sob um orçamento de contexto mais compacto, enquanto restringe parte das informações financeiras. O limite de 4.096 tokens, por sua vez, abrange integralmente as sequências observadas nos dois conjuntos de dados e permite avaliar o raciocínio financeiro com o contexto completo. A comparação investiga, portanto, o equilíbrio entre a preservação do contexto financeiro e o desempenho na tarefa industrial, considerando conjuntamente as demais diferenças de configuração entre as baterias. As configurações completas são apresentadas na Tabela 1.

Tabela 1 – Conjuntos de dados, configurações e hiperparâmetros principais

| Item | Bateria A | Bateria B |
|---|---|---|
| Limite treino/inferência | 1.024 / 1.024 | 4.096 / 4.096 |
| Taxa de aprendizado — FT-FinQA | $2\times10^{-4}$ | $2\times10^{-4}$ |

| | | |
|---|---|---|
| Taxa de aprendizado — FT-Failure/Híbrido | $2\times10^{-4}$ | $5\times10^{-5}$ |
| Microbatch × acumulação | 4 × 8 | 2 × 16 |
| Lote efetivo; épocas; semente | 32; 3; 42 | 32; 3; 42 |
| QLoRA / LoRA | NF4; r=8; α=16; dropout=0,1 | NF4; r=8; α=16; dropout=0,1 |

Fonte: elaboração própria a partir dos manifestos de execução preservados.

Nota: NF4 corresponde ao formato NormalFloat de 4 bits; r representa o posto dos adaptadores e α, seu fator de escala.

Os ajustes foram executados em uma unidade de processamento gráfico (*Graphics Processing Unit* — GPU) H100 de 80 GB, utilizando QLoRA, quantização *NormalFloat* de 4 bits (NF4) e adaptadores LoRA nos módulos de atenção e de perceptron multicamadas (*Multi-Layer Perceptron* — MLP) (DETTMERS et al., 2023). Durante o treinamento, o prompt foi concatenado à resposta esperada, e as sequências excedentes foram truncadas à direita. Na inferência, somente o prompt foi fornecido ao modelo, com geração determinística da resposta. Os modelos foram treinados por três épocas, com validação ao final de cada uma e seleção do checkpoint com menor perda de validação.

No FinQA, a primeira expressão numérica extraída da resposta foi comparada ao gabarito após a normalização de espaços e separadores decimais, considerando tolerâncias absoluta e relativa de 0,001. No FailureSensorIQ, as alternativas identificadas foram reunidas em um conjunto, com eliminação de repetições, e comparadas ao conjunto esperado. A correspondência exata foi utilizada como métrica principal, enquanto o F1 macro, obtido pela média não ponderada dos escores F1 de cada rótulo, que combinam precisão e revocação, foi adotado como medida complementar (SOKOLOVA; LAPALME, 2009). Respostas sem número ou alternativa reconhecível foram mantidas no denominador e consideradas incorretas. O equilíbrio entre a acurácia financeira (A_F) e a acurácia industrial (A_I) foi sintetizado pela média harmônica apresentada na Equação (1):

$$H = 2\,A_F\,A_I / (A_F + A_I) \qquad (1)$$

Na Equação (1), A_F representa a acurácia numérica no FinQA e A_I representa a correspondência exata no FailureSensorIQ. Valores mais altos de H indicam maior equilíbrio relativo entre os desempenhos nos dois domínios, sem substituir a análise individual das métricas.

## 4 RESULTADOS E DISCUSSÃO

Os resultados apresentados na Tabela 2 evidenciam comportamentos distintos entre os ajustes especializados e o ajuste multidomínio. Conforme a Equação (1), na Bateria A, o FT-Híbrido alcançou o maior valor de H, com 18,75%, sugerindo o maior equilíbrio relativo entre os desempenhos financeiro e industrial nesse protocolo. O FT-FinQA elevou a acurácia financeira de 1,49%, no modelo base, para 10,45%, enquanto o FT-Failure alcançou o melhor desempenho industrial, com 96,63% de correspondência exata e F1 macro de 0,989. O FT-Híbrido obteve 10,61% no FinQA e 80,39% no FailureSensorIQ. Assim, o treinamento híbrido proporcionou o melhor equilíbrio relativo, mas não superou os modelos especializados em suas respectivas tarefas.

Tabela 2 – Resultados dos quatro modelos nas duas baterias

| Bateria | Modelo | FinQA Acur. num. | Failure Acur. conjunto | Failure F1 macro | H (%) |
|---|---|---|---|---|---|
| 1.024 | Base | 1,49% | 12,52% | 0,318 | 2,66% |
| 1.024 | FT-FinQA | 10,45% | 12,88% | 0,384 | 11,54% |
| 1.024 | FT-Failure | 8,29% | 96,63% | 0,989 | 15,27% |
| 1.024 | FT-Híbrido | 10,61% | 80,39% | 0,928 | 18,75% |
| 4.096 | Base | 1,82% | 18,29% | 0,408 | 3,31% |
| 4.096 | FT-FinQA | 15,42% | 11,55% | 0,336 | 13,21% |
| 4.096 | FT-Failure | 2,32% | 21,54% | 0,535 | 4,19% |
| 4.096 | FT-Híbrido | 6,47% | 12,03% | 0,449 | 8,41% |

Fonte: elaboração própria.

Na Bateria B, o FT-FinQA atingiu a maior acurácia financeira do estudo, com 15,42%, e a maior média harmônica da configuração, com H = 13,21%. Em contrapartida, o FT-Híbrido obteve 6,47% no FinQA e 12,03% no FailureSensorIQ, resultando em H = 8,41%. Portanto, o equilíbrio observado para o modelo híbrido na Bateria A não foi reproduzido na Bateria B. Como a taxa de aprendizado e o tamanho do microbatch também variaram entre os protocolos, essa diferença não pode ser atribuída exclusivamente ao aumento da janela de contexto.

Entre as 6.156 sequências completas de prompt e resposta do FinQA, 2.823 (45,86%) excederam o limite de 1.024 tokens. Nenhuma das 8.296 sequências do FailureSensorIQ ultrapassou esse limite, e nenhuma sequência dos dois conjuntos excedeu 4.096 tokens. O menor truncamento pode ter favorecido o FT-FinQA na Bateria B, mas as diferenças entre os protocolos impedem confirmar essa relação. No FailureSensorIQ, a diferença entre o F1 macro de 0,928 e a acurácia de correspondência exata de 80,39% sugere que parte dos rótulos foi reconhecida mesmo quando o conjunto completo não foi previsto corretamente. A inspeção exploratória identificou erros de cálculo no FinQA e conjuntos incompletos no FailureSensorIQ. Além disso, o avaliador financeiro considera apenas a primeira expressão numérica da resposta e não interpreta automaticamente escalas textuais, como *million* e *billion*.

## 5 CONCLUSÃO

Este estudo comparou ajustes especializados e multidomínio do Qwen2.5-7B-Instruct em tarefas de raciocínio financeiro e análise de falhas industriais. Os modelos especializados obtiveram os melhores resultados em seus respectivos domínios, enquanto o FT-Híbrido apresentou o maior equilíbrio apenas na Bateria A. Como diferentes parâmetros variaram entre as baterias, não foi possível atribuir as diferenças exclusivamente à janela de contexto.

Os resultados estão limitados a dois benchmarks, uma única semente e divisões aleatórias dos dados. Estudos futuros deverão controlar os hiperparâmetros separadamente, utilizar diferentes sementes e avaliar cenários que relacionem falhas industriais às suas consequências econômicas.

## REFERÊNCIAS

ALSYOUF, I. The role of maintenance in improving companies' productivity and profitability. International Journal of Production Economics, v. 105, n. 1, p. 70-78, 2007. DOI: https://doi.org/10.1016/j.ijpe.2004.06.057.

CHEN, Zhiyu et al. FinQA: a dataset of numerical reasoning over financial data. In: PROCEEDINGS OF THE 2021 CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING. Association for Computational Linguistics, 2021, p. 3697–3711. DOI: https://doi.org/10.18653/v1/2021.emnlp-main.300.

CONSTANTINIDES, Christodoulos et al. FailureSensorIQ: a multi-choice QA dataset for understanding sensor relationships and failure modes. arXiv, 2025. DOI: https://doi.org/10.48550/arXiv.2506.03278.

DETTMERS, T. et al. QLoRA: Efficient finetuning of quantized LLMs. Advances in Neural Information Processing Systems, v. 36, 2023. DOI: https://doi.org/10.52202/075280-0441.

HU, E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 10., 2022. Proceedings of the Tenth International Conference on Learning Representations. 2022. Disponível em: https://openreview.net/forum?id=nZeVKeeFYf9. Acesso em: 14 set. 2026.

JARDINE, A. K. S.; LIN, D.; BANJEVIC, D. A review on machinery diagnostics and prognostics implementing condition-based maintenance. Mechanical Systems and Signal Processing, v. 20, n. 7, p. 1483–1510, 2006. DOI: https://doi.org/10.1016/j.ymssp.2005.09.012.

SOKOLOVA, Marina; LAPALME, Guy. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009. DOI: https://doi.org/10.1016/j.ipm.2009.03.002.

YANG, A. et al. Qwen2.5 technical report. arXiv:2412.15115, 2024. DOI: https://doi.org/10.48550/arXiv.2412.15115.

## SOBRE O(S) AUTOR(ES)

[i] **NICOLI FELIPE**



Graduanda em Ciência de Dados pela Faculdade SENAI de Informática (2025-2026). Graduanda em Informática para negócios pela Fatec (2025-2027). Formada no técnico de administração pela ETEC de Mauá (2024). https://orcid.org/0009-0001-5123-5059

[ii] **VINICIUS DE JESUS SILVA**



Graduado em Ciência de Dados (2024–2025) pelo Centro Universitário SENAI-SP, Campus São Caetano do Sul – Centro. https://orcid.org/0009-0002-8151-9439

[iii] **JÉSSICA FRANZON CRUZ DO ESPÍRITO SANTO**



Possui graduação (Bacharelado) em Ciência da Computação (2018-2021) pela Universidade Paulista (UNIP); Pós-graduada em Gestão Educacional na Perspectiva Inclusiva (2022) pela Universidade Federal de Pelotas (UFPEL) e Pós-graduada em Psicopedagogia (2024) pela Faculdade das Américas (FAM); É Mestranda em Engenharia da Informação pela Universidade Federal do ABC. Atua como Professora na Faculdade Senai no campus Paulo Antônio Skaf no curso de Ciência de Dados. https://orcid.org/0000-0002-2812-3673