FINE-TUNING MULTIDOMÍNIO COM QLORA EM LLMS PARA RACIOCÍNIO FINANCEIRO E DIAGNÓSTICO INDUSTRIAL

MULTIDOMAIN QLORA FINE-TUNING OF LLMS FOR FINANCIAL REASONING AND INDUSTRIAL DIAGNOSIS

Jéssica Franzon Cruz do Espírito Santo[i]; **Nicoli Felipe**[ii]; **Vinicius de Jesus Silva**[iii]

i Mestranda em Engenharia da Informação (UFABC) e docente do Centro Universitário SENAI-SP, Campus São Caetano do Sul – Centro.

ii Graduanda em Ciência de Dados pelo Centro Universitário SENAI-SP, Campus São Caetano do Sul – Centro.

iii Graduado em Ciência de Dados pelo Centro Universitário SENAI-SP, Campus São Caetano do Sul – Centro.

RESUMO

Este estudo investiga a especialização do Qwen2.5-7B-Instruct para raciocínio financeiro e diagnóstico industrial por meio de QLoRA. Foram comparados o modelo base, dois ajustes especializados e um ajuste híbrido em duas baterias experimentais: a primeira com limite de 1.024 tokens e taxa de aprendizado de 2×10^{-4}; a segunda com limite de 4.096 tokens e taxas distintas entre os ajustes. No FinQA, a maior acurácia numérica foi obtida pelo FT-FinQA de 4.096 tokens (15,42%). No FailureSensorIQ, reavaliado como tarefa multirrótulo, o FT-Failure de 1.024 tokens atingiu 96,63% de acurácia de correspondência exata e F1 macro de 0,989. O FT-Híbrido de 1.024 tokens apresentou 10,61% no FinQA e 80,39% no domínio industrial, constituindo o melhor compromisso dentro da bateria comparável. Os resultados mostram benefícios da especialização, mas não permitem atribuir diferenças da segunda bateria apenas à janela de contexto, pois taxa de aprendizado e microbatch também variaram.

Palavras-chave: modelos de linguagem; QLoRA; FinQA; diagnóstico de falhas; aprendizado multidomínio.

ABSTRACT

This study investigates QLoRA-based specialization of Qwen2.5-7B-Instruct for financial reasoning and industrial diagnosis. The base model, two domain-specialized models, and a hybrid model were compared in two experimental batteries: one limited to 1,024 tokens with a 2×10^{-4} learning rate, and an exploratory 4,096-token battery with model-dependent learning rates. FT-FinQA at 4,096 tokens achieved the highest FinQA numerical accuracy (15.42%). On FailureSensorIQ, correctly evaluated as a multilabel task, FT-Failure at 1,024 tokens reached 96.63% exact-set accuracy and 0.989 macro F1. The 1,024-token hybrid reached 10.61% on FinQA and 80.39% on the industrial benchmark, representing the best balance within the comparable battery. Because more than context length changed, the second battery is reported separately rather than as a controlled truncation ablation.

Keywords: large language models; QLoRA; FinQA; fault diagnosis; multidomain learning.

1 INTRODUÇÃO

Decisões industriais e financeiras são interdependentes: falhas elevam custos de manutenção, paradas reduzem produção e receita, problemas de qualidade geram retrabalho e desperdício, e investimentos em automação alteram produtividade, custo e retorno. A análise conjunta desses efeitos pode melhorar o planejamento e a priorização de recursos, sobretudo em ambientes com grande volume de dados operacionais e contábeis.

Embora modelos de linguagem de grande porte processem linguagem e números, versões generalistas ainda apresentam limitações em cálculos multietapas, interpretação de tabelas financeiras e diagnóstico técnico específico. Trabalhos sobre FinQA e manutenção baseada em condição evidenciam que cada domínio demanda conhecimento e padrões de resposta próprios (CHEN et al., 2021; JARDINE; LIN; BANJEVIC, 2006). Ainda é pouco explorada a especialização de um único modelo capaz de preservar capacidades nos dois domínios sem favorecer indevidamente apenas um deles.

O objetivo é avaliar o Qwen2.5-7B-Instruct, ajustado com QLoRA, em quatro configurações — Base, FT-FinQA, FT-Failure e FT-Híbrido — e em duas baterias com limites de 1.024 e 4.096 tokens. As contribuições são: comparação cruzada sob protocolos documentados; correção da avaliação multirrótulo do FailureSensorIQ; e análise do efeito conjunto de contexto, taxa de aprendizado e composição dos dados.

Cenários sintéticos que relacionem ocorrências industriais a consequências financeiras não são reportados como resultado, por ainda não terem execução documentada.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 LLMs para raciocínio financeiro e diagnóstico industrial

O FinQA combina textos, tabelas e perguntas numéricas que exigem localizar valores e executar programas matemáticos (CHEN et al., 2021). No domínio industrial, o FailureSensorIQ reúne questões de múltipla escolha, inclusive multirrótulo, sobre sensores, condições operacionais e modos de falha. Enquanto o primeiro enfatiza raciocínio quantitativo contextual, o segundo exige distinção entre alternativas técnicas semanticamente próximas. A avaliação conjunta permite observar especialização e transferência, mas não substitui um teste integrado de causalidade econômico-operacional.

2.2 Fine-tuning eficiente com LoRA e QLoRA

LoRA introduz matrizes de baixa dimensão em módulos selecionados e mantém congelados os pesos principais (HU et al., 2021). QLoRA combina essa adaptação com quantização NF4 de 4 bits para reduzir memória durante o ajuste (DETTMERS et al., 2023). No Qwen2.5-7B-Instruct (YANG et al., 2024), essa estratégia viabilizou os experimentos em uma única GPU H100 de 80 GB. A taxa de aprendizado controla a magnitude de cada atualização: valores altos aceleram a adaptação, mas podem desestabilizar o treinamento ou apagar capacidades; valores baixos favorecem estabilidade, porém podem resultar em subajuste.

3 METODOLOGIA

Foram utilizados o FinQA no domínio financeiro e o FailureSensorIQ no domínio industrial. Os registros foram normalizados para formato de instrução, tokenizados com o tokenizer do Qwen2.5 e separados em treino, validação e teste. Os conjuntos de teste contêm 617 e 831 exemplos, respectivamente. Uma verificação por texto exato não encontrou prompts idênticos entre treino e teste, reduzindo o risco de vazamento direto, embora não exclua similaridade semântica.

As quatro configurações foram derivadas do mesmo modelo base: sem ajuste, especializado em FinQA, especializado em FailureSensorIQ e híbrido. A Bateria A limita treinamento e inferência a 1.024 tokens e usa taxa de 2×10^{-4} em todos os ajustes. A Bateria B aplica 4.096 tokens, preserva 2×10^{-4} no FT-FinQA e usa 5×10^{-5} no FT-Failure e no FT-Híbrido. Como microbatch e taxa também mudaram, as baterias representam protocolos distintos, não uma ablação controlada exclusivamente do truncamento.

Tabela 1 – Datasets, configurações e hiperparâmetros principais

Item	Bateria A	Bateria B
Limite treino/inferência	1.024 / 1.024	4.096 / 4.096
LR FT-FinQA	2×10^{-4}	2×10^{-4}
LR FT-Failure/Híbrido	2×10^{-4}	5×10^{-5}
Microbatch × acumulação	4 × 8	2 × 16
Batch efetivo; épocas; seed	32; 3; 42	32; 3; 42
QLoRA / LoRA	NF4; r=8; α=16; dropout=0,1	NF4; r=8; α=16; dropout=0,1
Avaliação	FinQA n=617; Failure n=831	FinQA n=617; Failure n=831

Fonte: elaboração própria a partir dos manifestos de execução preservados.

Os ajustes foram executados com QLoRA/NF4, LoRA nos módulos de atenção e MLP e precisão mista. O FinQA foi medido por acurácia numérica. O FailureSensorIQ

foi reprocessado a partir das predições salvas como tarefa multirrótulo: a métrica principal é a correspondência exata do conjunto de alternativas e a complementar é o F1 macro por rótulo. A geração foi determinística, e cada configuração foi comparada apenas dentro da bateria correspondente.

4 RESULTADOS E DISCUSSÃO

A Tabela 2 consolida os resultados. Na Bateria A, o FT-Híbrido obteve a maior acurácia financeira (10,61%) por pequena margem sobre o FT-FinQA (10,45%) e preservou desempenho industrial elevado (80,39%). O FT-Failure foi superior no FailureSensorIQ (96,63%). Portanto, o híbrido apresenta o melhor equilíbrio na matriz comparável, mas não supera o especialista industrial em seu próprio domínio.

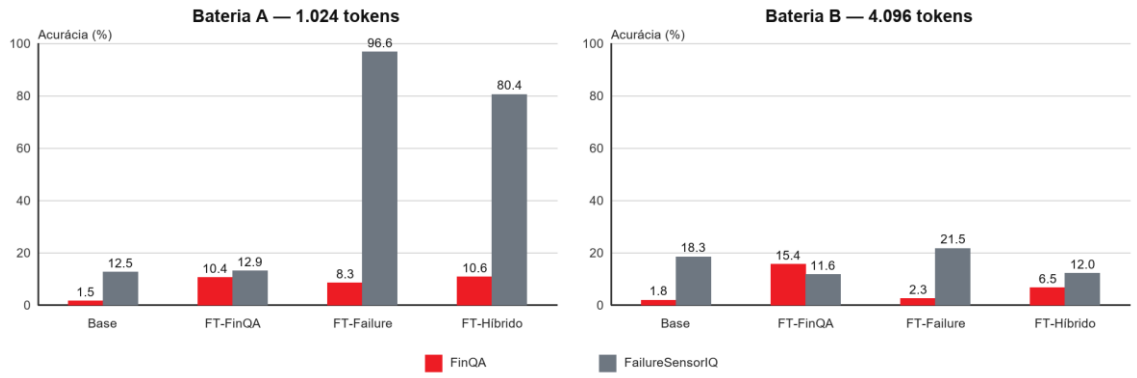
Tabela 2 – Resultados dos quatro modelos nas duas baterias

Bateria	Modelo	FinQA Acur. num.	Failure Acur. conjunto	Failure F1 macro
1.024	Base	1,49%	12,52%	0,318
1.024	FT-FinQA	10,45%	12,88%	0,384
1.024	FT-Failure	8,29%	96,63%	0,989
1.024	FT-Híbrido	10,61%	80,39%	0,928
4.096	Base	1,82%	18,29%	0,408
4.096	FT-FinQA	15,42%	11,55%	0,336
4.096	FT-Failure	2,32%	21,54%	0,535
4.096	FT-Híbrido	6,47%	12,03%	0,449

Fonte: elaboração própria. FailureSensorIQ reavaliado em 14 set. 2026 a partir das predições persistidas.

Na Bateria B, o FT-FinQA alcançou o melhor resultado financeiro de todo o estudo (15,42%), consistente com a redução do truncamento de entradas longas. Em contraste, FT-Failure e FT-Híbrido perderam desempenho industrial. Isso reforça que uma janela maior não beneficia uniformemente os domínios: as entradas industriais já eram curtas, e a redução da taxa de aprendizado para 5×10^{-5} pode ter produzido adaptação insuficiente. Como os fatores variaram juntos, essa explicação é uma hipótese, não uma relação causal demonstrada.

Figura 1 – Desempenho por domínio e bateria experimental



Fonte: elaboração própria. Acurácia FinQA é numérica; acurácia FailureSensorIQ exige correspondência exata do conjunto de rótulos.

A correção multirrótulo altera a interpretação anterior. A métrica antiga selecionava apenas o primeiro rótulo, subestimava modelos com falhas de parsing e superestimava previsões parcialmente corretas. Com a regra de conjunto exato, o Base sobe de 0,12% para 12,52% na Bateria A, enquanto o FT-Híbrido passa de 96,15% para 80,39%. O F1 macro mostra que o híbrido ainda reconhece bem os rótulos (0,928), embora erre combinações completas em parte dos exemplos.

Os erros financeiros concentram-se em extração de valores, cálculo multietapas e

respostas interrompidas; os industriais, em conjuntos incompletos de alternativas e confusões semânticas. A rodada de 4.096 tokens do FT-FinQA apresentou melhor checkpoint cedo no treinamento e piora posterior da perda de validação, sinal de instabilidade. Assim, o artigo não recomenda adotar um único truncamento por favorecer o FinQA: a escolha deve considerar a distribuição de comprimentos de cada domínio e ser testada com taxa de aprendizado controlada.

5 CONCLUSÃO

O fine-tuning eficiente especializou o Qwen2.5-7B-Instruct nos dois domínios, mas os resultados dependem da configuração experimental. A Bateria A oferece a comparação mais limpa: o FT-Híbrido apresenta o melhor equilíbrio geral, enquanto o FT-Failure domina o diagnóstico industrial. A Bateria B elevou o desempenho do especialista financeiro, porém não sustenta a conclusão de que 4.096 tokens sejam universalmente superiores, pois outros hiperparâmetros também mudaram.

As limitações incluem uma única semente, dois benchmarks, protocolo de resposta curta, instabilidade do FT-FinQA de 4.096 tokens e ausência de avaliação integrada documentada. Trabalhos futuros devem executar uma ablação controlada de contexto e taxa de aprendizado, testar truncamento ou agrupamento por domínio, repetir o treinamento com múltiplas sementes e criar cenários que liguem falhas, produção, custos e impacto financeiro. Somente após essa etapa será possível avaliar diretamente a capacidade multidomínio pretendida.

REFERÊNCIAS

CHEN, Z. et al. FinQA: A dataset of numerical reasoning over financial data. In: PROCEEDINGS OF EMNLP. Association for Computational Linguistics, 2021.

DETTMERS, T. et al. QLoRA: Efficient finetuning of quantized LLMs. 2023.

HU, E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models. 2021.

JARDINE, A. K. S.; LIN, D.; BANJEVIC, D. A review on machinery diagnostics and prognostics implementing condition-based maintenance. Mechanical Systems and Signal Processing, v. 20, n. 7, p. 1483–1510, 2006.

YANG, A. et al. Qwen2.5 technical report. arXiv:2412.15115, 2024.

SOBRE O(S) AUTOR(ES)

i JÉSSICA FRANZON CRUZ DO ESPÍRITO SANTO
Graduação em Ciência da Computação (UNIP, 2018–2021); pós-graduada em Gestão Educacional na Perspectiva Inclusiva (UFPEL, 2022) e em Psicopedagogia (FAM, 2024); mestranda em Engenharia da Informação (UFABC). Docente no Centro Universitário SENAI-SP, Campus São Caetano do Sul – Centro, no curso de Ciência de Dados. ORCID: 0000-0002-2812-3673.

ii NICOLI FELIPE
Graduanda em Ciência de Dados (2025–2026) pelo Centro Universitário SENAI-SP, Campus São Caetano do Sul – Centro. ORCID não informado.

iii VINICIUS DE JESUS SILVA
Graduado em Ciência de Dados (2024–2025) pelo Centro Universitário SENAI-SP, Campus São Caetano do Sul – Centro. ORCID: 0009-0002-8151-9439.